

Guide setup — Lab 1 : Apache Hop + DuckDB

Ce guide est la **référence unique de mise en place** du Lab 1. Il rassemble en un seul endroit les prérequis, l'installation, la création du projet Hop, la connexion DuckDB et la création des schémas.

Une fois ce setup terminé, le lab lui-même se fait dans `lab01_consignes.md`.

Windows d'abord. Les commandes sont données pour **Windows (PowerShell)** en premier, puis pour **Linux / macOS**. La majorité des postes étant sous Windows, suivez la colonne Windows sauf indication contraire.

Pour les **concepts Hop** (pipeline, workflow, transform), voir `docs/apache_hop_concepts.md`. Ce guide est le **pas-à-pas opérationnel de setup** ; il renvoie vers ce document au lieu de le recopier.

Vue d'ensemble

Le lab construit un ETL complet en deux parties :


- **Partie A** — Charger les CSV sources → `staging.*` dans DuckDB.
- **Partie B** — Transformer `staging.*` → schéma en étoile `warehouse.*`, chargement incrémental, budget vs réalisé.

`data/raw/` (CSV)

- Hop ETL (p01) → `staging.*`
- Hop ETL (p02..p05) → `warehouse.*`

Rôles de l'architecture - Hop, DuckDB

Les données transitent par une seule base locale ; Apache Hop est le chemin ETL visible.



Compétences nécessaires

- SQL de base : `SELECT` , `WHERE` , `JOIN` , `GROUP BY` , agrégations.
- Compréhension minimale des fichiers CSV.
- Différence conceptuelle entre système opérationnel et système analytique.
- Utilisation basique d'un terminal.

Étape 0 — Installation & prérequis

Logiciel	Rôle	Lien de téléchargement
Apache Hop	Ingestion visuelle (chemin officiel, pipeline GUI)	https://hop.apache.org/download/
DuckDB CLI	Moteur d'exploration local (requêtes <code>.read</code>)	https://duckdb.org/docs/installation/
Driver DuckDB JDBC	Connexion DuckDB depuis Hop (Partie B)	https://duckdb.org/docs/stable/clients/java
Git	Récupérer et mettre à jour le matériel	https://git-scm.com/downloads
Éditeur de texte	VS Code, IntelliJ, Cursor, Sublime Text...	https://code.visualstudio.com/

Java 17+

Apache Hop requiert **Java 17 minimum (Java 21 recommandé)**.

```
java -version
```

Si Java est absent ou trop ancien, l'installer depuis <https://adoptium.net>.

Apache Hop 2.x

Télécharger Apache Hop Desktop (version 2.x récente) depuis <https://hop.apache.org/download/> et le décompresser dans un dossier de votre choix.

	Lancement de Hop GUI
Windows	double-clic sur <code>hop-gui.bat</code> (ou <code>.\hop-gui.bat</code> dans le dossier Hop)
Linux / macOS	<code>./hop-gui.sh</code>

DuckDB CLI

DuckDB est le **moteur d'exploration** du lab : une fois `staging.*` chargé, les analyses se font avec la CLI.

Windows (recommandé — winget) :

```
winget install DuckDB.cli
```

`winget` place `duckdb.exe` dans votre dossier utilisateur et l'ajoute **automatiquement au PATH**. DuckDB sous Windows requiert le **Microsoft Visual C++ Redistributable** (déjà présent sur la plupart des postes).

Important : après l'installation, **ouvrez un nouveau terminal** pour que le PATH mis à jour soit pris en compte, puis vérifiez :

```
duckdb --version
```

Linux / macOS : installer depuis <https://duckdb.org/docs/installation/>, puis `duckdb --version`.

Driver DuckDB JDBC (Partie B avec Hop)

Le driver JDBC permet à Hop de se connecter à DuckDB. **Il n'est pas fourni dans ce dépôt** : il faut le télécharger.

1. Télécharger `duckdb-jdbc-*.jar` depuis <https://duckdb.org/docs/stable/clients/java>.
2. Le copier dans le dossier `lib/` de votre **installation Apache Hop** (ex. `.../hop/lib/`).
3. **Redémarrer Hop** pour qu'il prenne en compte le nouveau driver.

Sans ce `.jar`, le **Test connection** de l'étape 2 échoue.

Git & éditeur de texte

```
git --version
```

Si la commande est absente, installer Git depuis <https://git-scm.com/downloads>. Pour l'édition : VS Code, IntelliJ, Cursor, Sublime Text ou équivalent.

Étape 1 — Créer le projet Hop (étape à ne pas rater)

1. Lancer Hop GUI.
2. **File** → **New Project**.
3. **Project Name** : `Lab1` (ou autre).
4. **Project Home** : le chemin **absolu** du dossier `labs/lab01_hop_duckdb` — c'est-à-dire **le dossier du lab lui-même, PAS le sous-dossier hop/**. Exemple :

```
<racine-du-dépôt>\labs\lab01_hop_duckdb
```

5. **Metadata base folder** (*crucial*) : par défaut Hop utilise `${PROJECT_HOME}/metadata`. **Or, dans ce dépôt, la métadonnée est rangée sous `hop/metadata/`**. Vous **devez** donc changer ce champ pour :

```
${PROJECT_HOME}/hop/metadata
```

Sinon la connexion `DuckDB_Lab1` (et toute la métadonnée) **ne sera pas trouvée**.

6. Valider (OK / Finish).

Pourquoi c'est important : `${PROJECT_HOME}` est la variable que Hop utilise pour résoudre tous les chemins relatifs. Si le Project Home est faux, ou si le metadata base folder ne pointe pas vers `hop/metadata`, alors `${PROJECT_HOME}/duckdb/lab1.duckdb`, les chemins des pipelines et la connexion ne se résolvent pas. **C'est la cause d'erreur n°1 au démarrage** (voir `docs/apache_hop_concepts.md`).

Étape 2 — Vérifier la connexion DuckDB

La connexion est déjà définie dans `hop/metadata/rdbms/DuckDB_Lab1.json` et pointe vers `${PROJECT_HOME}/duckdb/lab1.duckdb` (le fichier `.duckdb` est créé au premier chargement).

1. Ouvrir le panneau **Metadata** (barre latérale gauche).
2. Déplier **Relational Database Connections**.
3. Clic droit sur `DuckDB_Lab1` → **Test connection**.
4. Résultat attendu : **Connection successful**.

En cas d'échec :

- Vérifier que `duckdb-jdbc-*.jar` est bien dans le `lib/` de l'installation Hop.
- Redémarrer Hop après avoir copié le `.jar`.

- Vérifier que **Project Home** = `labs/lab01_hop_duckdb` (et **pas** le sous-dossier `hop/`), et que le metadata base folder pointe vers `${PROJECT_HOME}/hop/metadata`.

Étape 3 — Création des schémas (une seule fois) + vérification

Avant de lancer un pipeline Hop, créer les schémas dans DuckDB. Se placer **dans** le dossier du lab (les scripts utilisent des chemins relatifs) :

Windows (PowerShell) :

```
cd labs/lab01_hop_duckdb

# Schémas (staging, warehouse, control)
duckdb duckdb/lab1.duckdb ".read sql/00_create_schema.sql"

# Structure des tables de staging
duckdb duckdb/lab1.duckdb ".read sql/10_create_staging_schema.sql"
```

Linux / macOS :

```
cd labs/lab01_hop_duckdb
duckdb duckdb/lab1.duckdb ".read sql/00_create_schema.sql"
duckdb duckdb/lab1.duckdb ".read sql/10_create_staging_schema.sql"
```

Vérifier que les schémas existent

```
duckdb duckdb/lab1.duckdb "SELECT * FROM information_schema.schemata;"
```

Vous devez voir apparaître `staging`, `warehouse` et `control` (en plus des schémas système). Si l'un manque, relancer le script `00_create_schema.sql`.

Les **séquences** et les tables du warehouse (`sql/20_create_warehouse_schema.sql`) ainsi que le schéma de contrôle (`sql/40_create_control_schema.sql`) sont créés au début de la Partie B — voir `lab01_consignes.md`.

Étape 4 — Lancer le lab

Les schémas et la connexion sont prêts. **Le setup est terminé.** Suivez maintenant les consignes du lab dans `lab01_consignes.md` :

- **Partie A** : ingestion des CSV vers `staging.*` avec Hop, puis exploration DuckDB. Guide pas-à-pas du premier flux : `hop/README_pipeline_apache_hop.md` et `hop/blueprints/p01_blueprint.md`.
- **Partie B** : schéma en étoile, chargement incrémental, budget vs réalisé. Réglages des transforms : `hop/blueprints/p02_p03_blueprint.md`, `p04_blueprint.md`, `p05_blueprint.md`. L'ordre opérationnel (pré-requis warehouse, dimensions, faits, workflows) est détaillé directement dans `lab01_consignes.md` (Partie B).

Chemin de secours CLI (si Hop est indisponible, ou pour vérifier les résultats) :

```
duckdb duckdb/lab1.duckdb ".read sql/01_load_staging_tables.sql" # Partie A : staging
duckdb duckdb/lab1.duckdb ".read sql/50_initial_full_load.sql"   # Partie B : chargement c
duckdb duckdb/lab1.duckdb ".read sql/51_incremental_load.sql"    # Partie B : incrémental
duckdb duckdb/lab1.duckdb ".read sql/52_actuals_vs_budget.sql"   # Partie B : budget vs ré
```

Les scripts SQL servent d'**oracle de validation** et de chemin de secours. Le chemin principal du lab reste **Hop natif** (transforms visibles sur le canvas).

Préparation avant la séance

1. Décompresser le dossier du lab.
2. Ouvrir `data/raw/` et repérer les fichiers principaux, les fichiers `_april` et le fichier budget.
3. Lire `docs/data_dictionary.md`.
4. Lire `docs/business_questions.md`.
5. Préparer un dossier local de travail (aucun rendu n'est demandé : le lab se fait en séance).

Note pédagogique

dbt n'est pas utilisé dans ce lab. Il sera introduit au Lab 2, après les séances sur la modélisation dimensionnelle.